PROTOTYPE · MVP DE DÉMONSTRATION

Simulateur d'audition d'enfant selon le protocole NICHD

Un enfant simulé dont le comportement est piloté par des règles, un modèle de langue local pour la parole, et un retour objectif à l'apprenant.

Personnages et faits entièrement fictifs

POURQUOI

S'entraîner sans enfant réel, avec un retour mesurable

- Le protocole NICHD structure l'audition en **phases** et privilégie les **questions ouvertes**.
- Les questions fermées ou suggestives **dégradent** le témoignage : réponses au hasard, acquiescement, faux détails.
- S'entraîner demande de la pratique répétée, avec un retour précis sur chaque question posée.

Ce que fait le simulateur

- Un enfant simulé (5 à 12 ans) répond en français, de façon cohérente sur tout l'entretien.
- Les **faits réels** du scénario sont connus : on peut donc mesurer ce qui a été recueilli… et ce qui a été contaminé.
- Chaque intervention est codée selon la typologie NICHD, les phases sont suivies.
- Un retour structuré est produit à la fin.

PRINCIPE CENTRAL

Architecture hybride : les règles décident, le LLM ne fait que parler



Cohérence

Le personnage ne dérive pas : ce qu'il sait et a déjà dit est tenu par le moteur, pas par le LLM.

Reproductibilité

Même graine + mêmes questions = même entretien. Chaque session peut être rejouée sans LLM.

Contrôle du contenu

Le LLM ne peut dire que les faits autorisés à ce tour ; révélations volontairement non explicites.

Voir docs/adr/0001-architecture-hybride-moteur-deterministe.md

ENTRÉE

La fiche de scénario

```yaml
child_profile:
  name: Léo
  age: 5
  reluctance: 0.2      # réticence
  verbal_skills: 0.4
  suggestibility: 0.8
target_event:            # faits de référence
  segments:
    - id: during          # before / during / after
      units:
        - id: d_pousse
          category: what   # qui, quoi, où, quand, fréquence
          centrality: central
          value: "le monsieur au blouson rouge
                  a poussé Monsieur Bertin"
          anchors: [poussé, pousser]
neutral_event: ...        # pour la pratique narrative
```

- Les faits sont découpés en **unités d'information**, centrales ou périphériques, ordonnées dans le temps.
- Les **ancres** permettent de repérer chaque fait dans les réponses (fuite, omission) et dans la synthèse de l'apprenant.
- Un **événement neutre** sert à la pratique narrative.
- `nichd-sim check-scenario` vérifie une fiche ; un guide de rédaction l'accompagne.

> **7 scénarios** (brouillons) : 5 à 12 ans, victimes et témoins, faits uniques et répétés, réticences variées.

LE CŒUR

Moteur de comportement : chaque type de question a ses effets

TYPE DE QUESTION	EXEMPLE	CE QUE L'ENFANT FAIT
invitation	« Raconte-moi tout ce qui s'est passé. »	Récit libre : 2 à 4 unités **centrales** selon l'âge, modulé par la verbosité.
invitation indicée	« Tu as parlé des messieurs, raconte-moi plus. »	Détaille le passage cité.
directive	« Qui a poussé qui ? »	Ne livre **que** le détail ciblé, ou « je sais pas ».
choix multiple	« C'était le matin ou l'après-midi ? »	Réponse partiellement aléatoire, **biais de récence** (dernière option).
suggestive	« Il avait un couteau, c'est ça ? »	Peut **acquiescer** et intégrer un faux détail, selon la suggestibilité et l'âge.
soutien · règle de base	« Tu peux me dire “je sais pas”. »	Baisse la réticence / l'acquiescement pour la suite.

Paramètres par tranche d'âge (4–6, 7–9, 10–12) dans un fichier unique, chacun avec sa source bibliographique (Lamb et al., Brown & Lamb, Ceci & Bruck, Fritzley & Lee…). Valeurs estimées : à calibrer.

MESURER LE RISQUE

Suggestion, contamination et dévoilement

Contamination

- Une suggestion **fausse** acceptée crée un **faux détail** (c1, c2…), rattaché au tour et au type de question qui l'ont introduit.
- L'enfant peut le **répéter plus tard** comme s'il s'agissait d'un souvenir : il est intégré à son récit.
- Une suggestion qui tombe juste est quand même signalée : **faute de technique**.

Dévoilement

- Un enfant réticent ne parle pas tout de suite : chaque question ajoute une **pression** ; le dévoilement survient au-delà d'un seuil.
- Obtenu sous une pression trop directive, il est signalé comme **dévoilement forcé**. Ne pas dévoiler reste un résultat légitime.

Tour 12 — **question suggestive**

Interviewer : Le monsieur au blouson rouge avait un couteau, c'est ça ?

Léo : *Oui, il avait un couteau.*

Décision du moteur : `acquiesce` — acquiescement 0,56 → faux détail `c1`

Aucun couteau dans les faits réels. Si l'apprenant le reprend dans sa synthèse, le retour le signale : *« Faux détail repris comme un fait »*.

PROTOCOLE

Les phases sont suivies et ont un effet

Rapport	Règles de base	Pratique narrative	Transition	Phase substantive	Clôture
fait connaissance	« je sais pas » permis	événement neutre	sans nommer les faits	récit des faits	remerciements

Effets sur l'enfant

- Soutien et rapport → **réticence** en baisse.
- Règles de base → **acquiescement** en baisse (moins de « oui » aux suggestions).
- Pratique narrative → **verbosité** en hausse : récits plus riches ensuite.

Écarts détectés

- Phase sautée ou écourtée.
- Question ciblée posée avant le récit libre.
- Dévoilement forcé.
- Clôture absente.

ÉVALUATION AUTOMATIQUE

Le classifieur NICHD : un skill versionné

- Le **skill** formalise le protocole : spécification de la typologie, schéma JSON de sortie, 50 exemples commentés.
- Pour chaque énoncé : **type** de question, **fait visé** dans le catalogue du scénario, proposition suggérée, indice de phase.
- Sortie contrainte par schéma, température 0 ; en cas d'erreur, repli « autre » tracé.
- Évalué sur un jeu de **104 énoncés** annotés (dont 12 ambigus).

RÉFLEXION	κ	TYPE	CIBLE	LATENCE MÉD.
sans	0,956	96,2 %	90,7 %	3,6 s
basse	0,945	95,2 %	88,9 %	8,4 s
moyenne (défaut)	**0,978**	**98,1 %**	90,7 %	13,1 s

κ de Cohen contre l'annotation de référence. Priorité actuelle : la précision ; la latence sera optimisée ensuite. Les écarts portent sur 2 à 3 énoncés : à confirmer sur un jeu plus large.

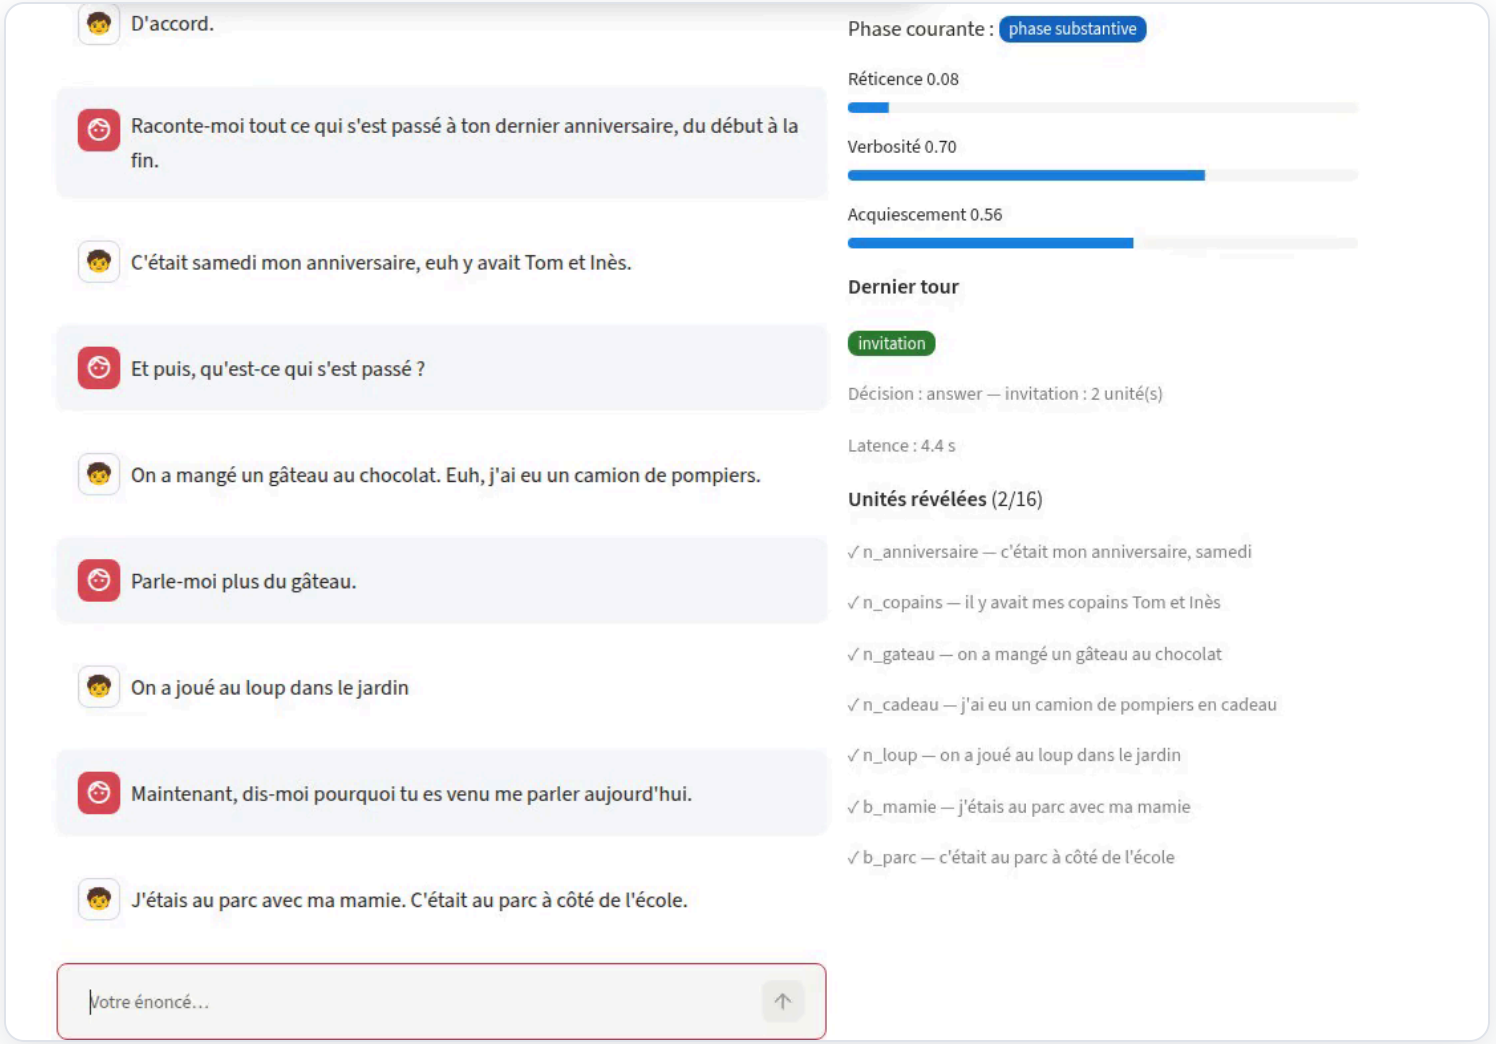
La classification manuelle par préfixes (`[inv]`, `[dir:u]`, `[sug:u=…]`) reste disponible pour tester sans LLM.

DÉMONSTRATION

L'entretien, vu par le formateur

- L'apprenant pose ses questions librement, à l'écrit.
- Le **mode formateur** montre en direct : phase courante, réticence, verbosité, acquiescement, type et cible de la dernière question, décision du moteur, faits révélés.
- Un **mode hors ligne** (sans LLM) permet une démo sans GPU.

> Vidéo complète (3 min 30) : `demo_nichd.mp4`, dans ce dossier.



SORTIE

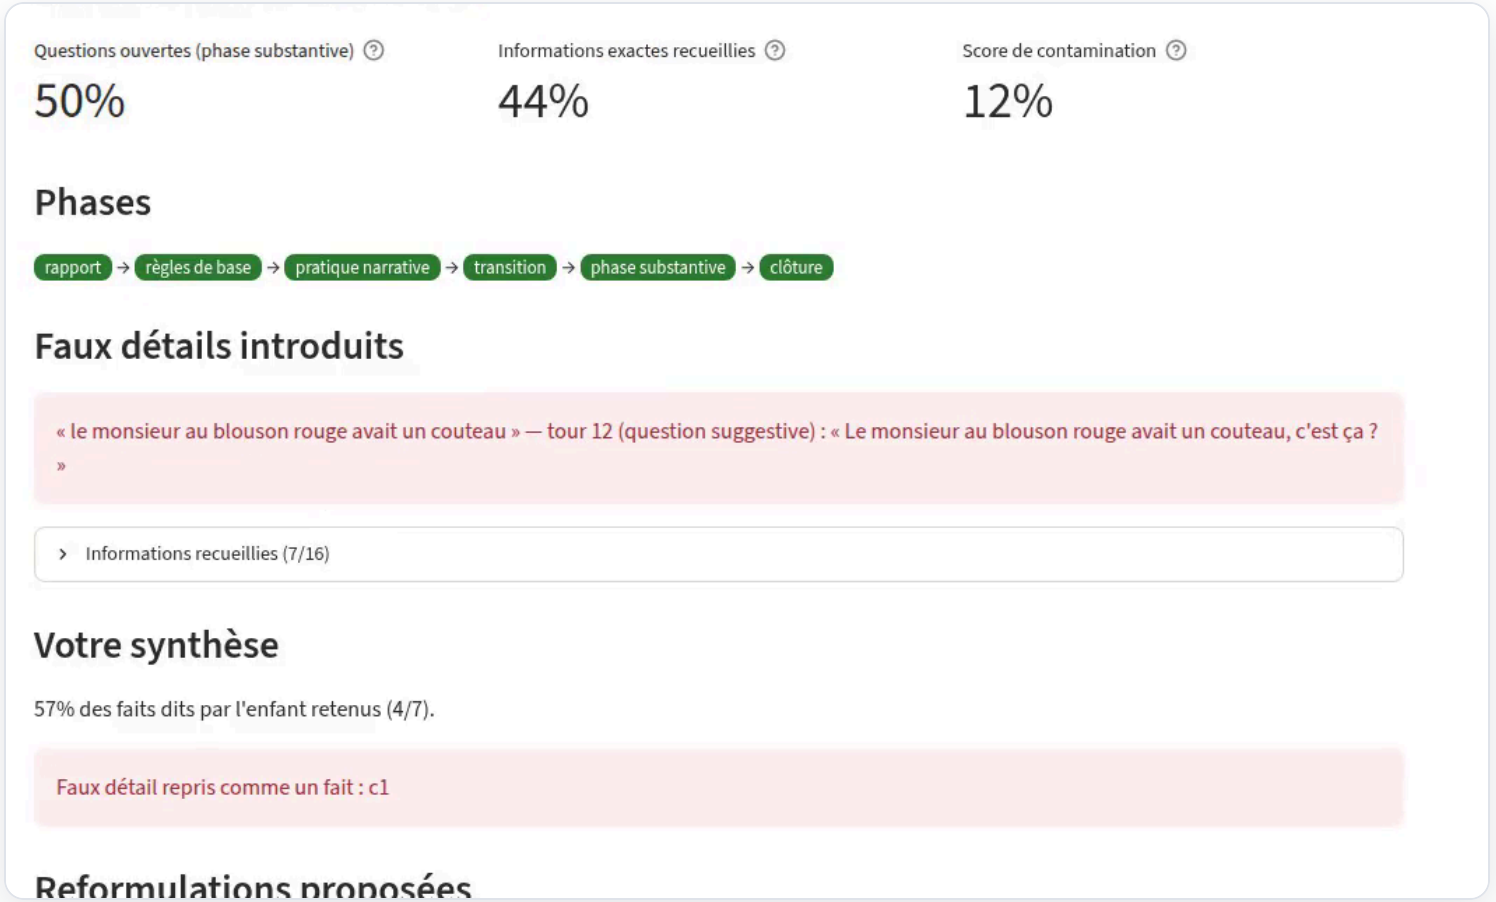
Le retour à l'apprenant

50 % questions ouvertes

44 % faits recueillis

12 % contamination

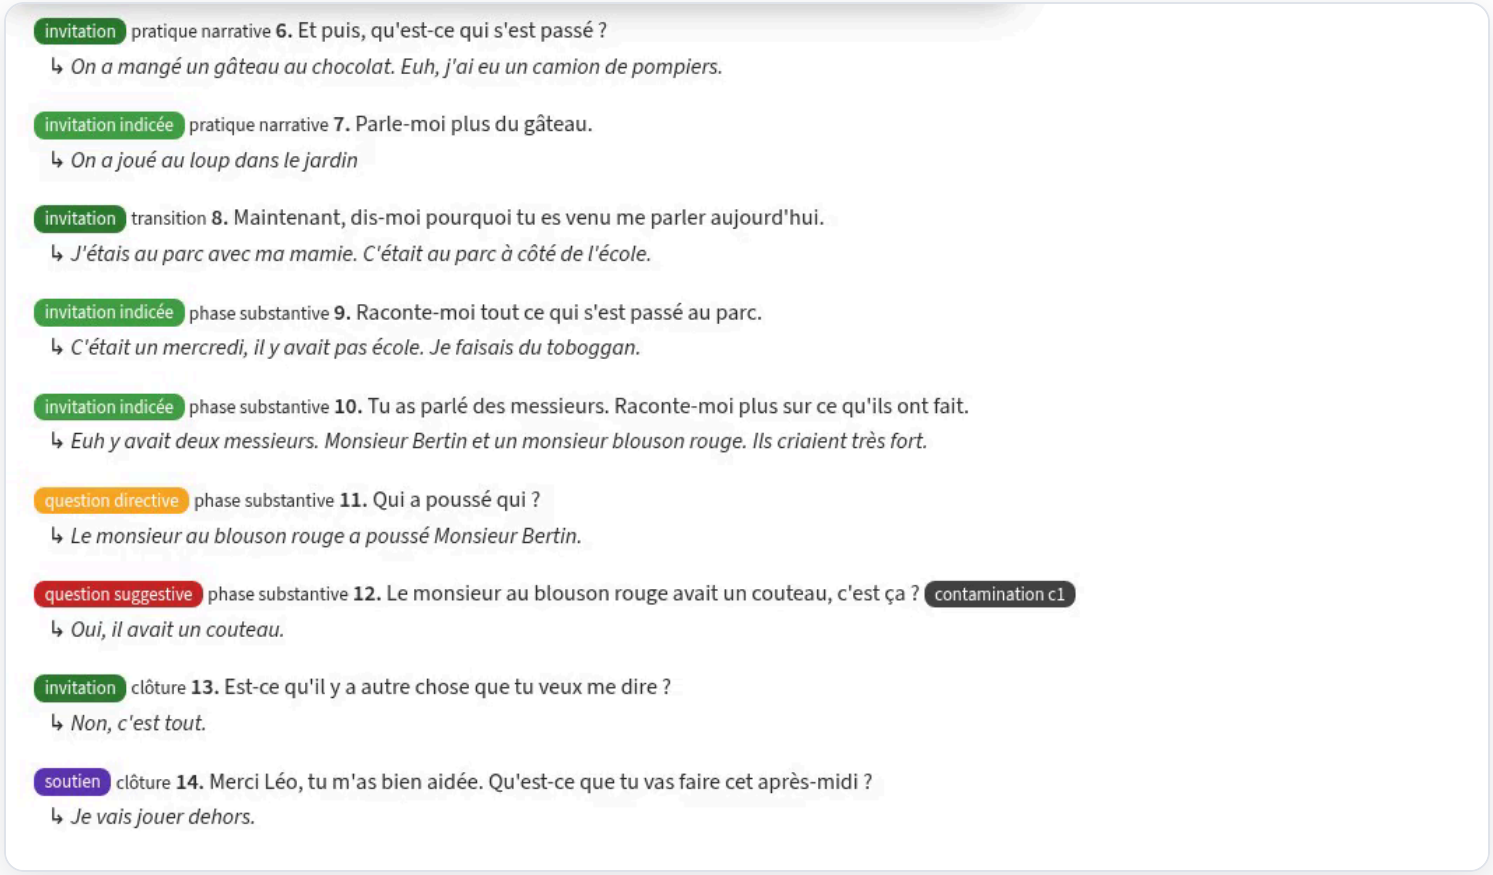
- **Métriques objectives**, calculées sans LLM à partir des faits de référence.
- Phases parcourues et écarts, faux détails avec leur origine.
- **Synthèse de l'apprenant** confrontée aux déclarations de l'enfant.
- Reformulations proposées (LLM, à lire avec esprit critique) et transcription annotée.



SORTIE

Transcription annotée selon la typologie

- Chaque tour porte son type NICHD (couleur), sa phase et ses alertes (contamination, hors protocole…).
- Lecture immédiate de la dérive : **ouvert** → **directif** → **suggestif**.
- Les sessions sont exportables en **CSV pour des codeurs humains**, afin de mesurer l'accord avec le classifieur.



TRAÇABILITÉ

Tout est journalisé, rejouable, local

Journal de session

JSON par session : paramètres, versions (skill, modèle), et pour chaque tour la classification, l'état avant/après, la décision, les tentatives de réalisation, les latences.

Rejeu

`nichd-sim replay` reconstruit l'entretien **sans LLM** et vérifie que le moteur reprend exactement les mêmes décisions.

100 % local

Qwen 3.8 (27 B) servi par **Ollama** sur la station (2 × TITAN RTX). Aucune donnée ne sort de la machine.

Filtre de sortie

Lexique interdit, fait non autorisé (fuite), fait autorisé oublié (omission), réponse vide ou bavarde. Après 2 essais : réponse gabarit. **0 repli sur 48 tours** de test.

Qualité

253 tests automatisés ; développement par tickets GitHub et PR empilées.

PRISE EN MAIN

Utilisation

```
# interface web (écoute en local)
uv run nichd-sim ui
# depuis un poste distant : tunnel SSH
ssh -L 8501:localhost:8501 station

# en terminal
uv run nichd-sim play scenarios/s01_bagarre_parc.yaml \
    --classifier llm --realizer llm --trainer

# démo fluide : classifieur sans réflexion
uv run nichd-sim play ... --classifier-think off

# outils
uv run nichd-sim replay sessions/session_xxx.json
uv run nichd-sim export sessions/session_xxx.json
uv run nichd-sim check-scenario scenarios/*.yaml
uv run nichd-sim eval-classifier
```

- Choisir un scénario, une graine, activer ou non le mode formateur.
- Mener l'audition comme en situation réelle.
- « Terminer l'entretien », rédiger sa synthèse, lire le retour.

Latence par tour : ~4 s sans réflexion, ~14 s en réflexion moyenne (défaut).

SUITE

Limites et prochaines étapes

À valider par des humains

- **Paramètres** du moteur : valeurs estimées depuis la littérature, à calibrer.
- **Scénarios** : relecture par un formateur NICHD, en priorité les plus sensibles (violences conjugales, négligence).
- **Accord classifieur / codeurs humains** sur des sessions réelles (export CSV prêt).
- **Réalisme** des réponses jugé en aveugle par des formateurs.

Techniques

- Optimiser la latence du classifieur (actuellement ~13 s).
- Étendre le jeu de test du classifieur aux 7 scénarios.
- Suivre la progression des apprenants d'une session à l'autre.
- Petites corrections d'interface : panneau formateur fixe, faux détails affichés en clair dans la synthèse.